

Distribuição Binomial

A distribuição binomial é um modelo matemático usado para descrever situações onde realizamos um experimento várias vezes — digamos, n vezes — e em cada vez, o resultado pode ser só um de dois possíveis: **sucesso** ou **fracasso**. Por exemplo:

- Lançar uma moeda várias vezes e contar quantas vezes sai “cara” (considerando “cara” como sucesso).
- Testar se um componente eletrônico funciona ou não em vários testes, contando quantos testes foram “sucesso” (funcionou).
- Em uma pesquisa, perguntar a várias pessoas se aprovam ou não um certo produto, contando quantos aprovaram.

O objetivo da distribuição binomial é calcular a **probabilidade** de obter exatamente k sucessos em n tentativas.

Por que a distribuição é discreta?

Porque o número de sucessos k só pode ser um número inteiro entre 0 e n (não faz sentido ter 2,5 sucessos, por exemplo). Ou seja, os possíveis valores de k são discretos, o que justifica chamar essa distribuição de **discreta**.

Tentativas independentes e com probabilidade constante

Para a distribuição binomial funcionar, duas condições importantes precisam ser verdadeiras:

- **Independência:** o resultado de cada tentativa não pode influenciar o resultado das outras. Por exemplo, se você lança uma moeda, o resultado da jogada 1 não muda a probabilidade da jogada 2.
 - **Probabilidade constante:** a chance de sucesso em cada tentativa é sempre a mesma p . Não pode variar de tentativa para tentativa.
-

Comparação com a distribuição de Bernoulli

A distribuição de Bernoulli é um caso especial da distribuição binomial.

- A **Bernoulli** modela uma única tentativa com dois resultados possíveis (sucesso ou fracasso).
- A **binomial** modela a soma dos sucessos em n tentativas independentes, cada uma com distribuição Bernoulli.

Em outras palavras:

- Uma variável aleatória Bernoulli X tem valor 1 (sucesso) com probabilidade p e 0 (fracasso) com probabilidade $1-p$.

- Uma variável aleatória Binomial Y é a soma de n variáveis Bernoulli independentes. Ou seja, $Y = X_1 + X_2 + \dots + X_n$, onde cada X_i é Bernoulli(p).

Visualização intuitiva

- Bernoulli: um único tiro, você acerta (1) ou erra (0).
- Binomial: você dá n tiros e quer saber quantos acertos (1's) teve no total.

Por que isso importa?

Muitos fenômenos do dia a dia, testes científicos e processos industriais podem ser modelados usando a distribuição binomial, pois muitos eventos ocorrem em sequência e são independentes, com resultados binários.

Por exemplo:

- Qual a chance de uma fábrica produzir exatamente 3 produtos defeituosos em uma caixa com 20 itens, sabendo que a probabilidade de defeito é 5%?
- Quantos emails spam vou receber em 10 emails, sabendo que 40% dos emails são spam?

Beleza! Vou explicar a fórmula da distribuição binomial, detalhando cada parte, como lê-la e o que significa cada elemento.

Fórmula da distribuição binomial

A probabilidade de obter exatamente k sucessos em n tentativas independentes, com probabilidade de sucesso p em cada tentativa, é dada por:

\$\$

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n - k}$$

\$\$

Como ler essa fórmula

"A probabilidade de que a variável aleatória X seja igual a k (ou seja, de obter exatamente k sucessos), é igual ao número de combinações possíveis de k sucessos em n tentativas, multiplicado pela probabilidade de sucesso elevada a k , vezes a probabilidade de fracasso elevada a $n-k$."

Explicação de cada termo

1. $P(X = k)$

- Representa a probabilidade de ocorrer exatamente k sucessos.
- Exemplo: a chance de dar exatamente 4 caras em 10 lançamentos de moeda.

2. $\binom{n}{k}$ (coeficiente binomial)

- Também lido como "n escolhe k".
- Representa o **número de formas diferentes** de escolher quais k tentativas, dentre as n totais, serão os sucessos.
- Fórmula:

$$\binom{n}{k} = \frac{n!}{k! (n-k)!}$$

$$\text{onde } n! \text{ (fatorial) é o produto de todos os inteiros positivos até } n.$$

- Exemplo: em 10 jogadas, quantas maneiras diferentes posso ter exatamente 4 caras? São essas maneiras que o coeficiente binomial conta.

3. p^k

- É a probabilidade de sucesso, elevada à potência do número de sucessos.
- Como cada sucesso tem probabilidade p , a chance de k sucessos ocorrerem juntos (em uma sequência fixa) é $p \times p \times \dots \times p = p^k$.

4. $(1-p)^{n-k}$

- É a probabilidade de fracasso, elevada ao número de fracassos (que é $n - k$).
- Como a probabilidade de fracasso em uma tentativa é $1-p$, e ocorrem $n-k$ fracassos, a chance deles ocorrerem juntos é $(1-p)^{n-k}$.

Por que multiplicar tudo?

- Primeiro, você escolhe **quais** tentativas são os sucessos — e o número dessas combinações é $\binom{n}{k}$.
- Depois, para **cada uma dessas combinações específicas**, a chance de ocorrer exatamente essa sequência (com k sucessos e $n-k$ fracassos) é a multiplicação das probabilidades individuais, $p^k \times (1-p)^{n-k}$.
- Como essas combinações são mutuamente exclusivas (não se sobrepõem), somamos a probabilidade para todas elas multiplicando o número de combinações pelo valor da probabilidade de cada uma.

Um exemplo rápido para fixar

Se você quer calcular a probabilidade de obter exatamente 3 caras em 5 lançamentos de moeda:

- $n = 5$
- $k = 3$
- $p = 0.5$ (moeda justa)

Então:

\$\$

$$P(X=3) = \binom{5}{3} (0.5)^3 (1-0.5)^{5-3} = 10 \times 0.125 \times 0.25 = 0.3125$$

\$\$

Ou seja, cerca de 31,25% de chance.

Perfeito! Vamos fazer **dois exemplos práticos** com a **fórmula da distribuição binomial**, mostrando passo a passo.

✅ Exemplo 1: Probabilidade de passar em uma prova de múltipla escolha

Um aluno tem 5 questões de múltipla escolha com duas alternativas cada (V ou F), e **chuta todas as respostas**. Qual a probabilidade de ele acertar exatamente 2 questões?

Informações:

- $n = 5$ (5 questões)
- $k = 2$ (quer acertar exatamente 2)
- $p = 0.5$ (probabilidade de acerto por chute)
- $1 - p = 0.5$ (probabilidade de errar)

Aplicando a fórmula:

\$\$

$$P(X = 2) = \binom{5}{2} \cdot (0.5)^2 \cdot (0.5)^{5-2}$$

\$\$

\$\$

$$\binom{5}{2} = \frac{5!}{2! \cdot 3!} = \frac{120}{2 \cdot 6} = 10$$

\$\$

\$\$

$$P(X = 2) = 10 \cdot (0.25) \cdot (0.125) = 10 \cdot 0.03125 = 0.3125$$

\$\$

◆ **Resultado: 31,25%** de chance de acertar exatamente 2 questões chutando.

✅ Exemplo 2: Defeitos em peças de uma fábrica

Uma máquina tem uma taxa de defeito de 10%. Se ela produz 8 peças, qual a probabilidade de exatamente 1 peça sair com defeito?

Informações:

- $n = 8$ (peças)

- $k = 1$ (exatamente 1 defeituosa)
- $p = 0.1$ (chance de defeito = sucesso)
- $1 - p = 0.9$ (chance de peça boa = fracasso)

Aplicando a fórmula:

\$\$

$$P(X = 1) = \binom{8}{1} \cdot (0.1)^1 \cdot (0.9)^{8-1}$$

\$\$

\$\$

$$\binom{8}{1} = 8$$

\$\$

\$\$

$$P(X = 1) = 8 \cdot 0.1 \cdot (0.9)^7$$

\$\$

\$\$

$$(0.9)^7 \approx 0.4783$$

\$\$

\$\$

$$P(X = 1) \approx 8 \cdot 0.1 \cdot 0.4783 = 0.3826$$

\$\$

Resultado: aproximadamente 38,26% de chance de ter exatamente 1 peça defeituosa entre as 8.

Exemplo em python

```
import matplotlib.pyplot as plt
from scipy.stats import binom
import numpy as np

# Exemplo 1: Prova de múltipla escolha (n = 5, p = 0.5, k = 0 a 5)
n1 = 5
p1 = 0.5
x1 = np.arange(0, n1 + 1)
pmf1 = binom.pmf(x1, n1, p1)

# Exemplo 2: Defeitos em peças (n = 8, p = 0.1, k = 0 a 8)
n2 = 8
p2 = 0.1
x2 = np.arange(0, n2 + 1)
pmf2 = binom.pmf(x2, n2, p2)

# Plotando ambos os gráficos lado a lado
fig, axs = plt.subplots(1, 2, figsize=(12, 5))

# Gráfico do Exemplo 1
```

```

axs[0].bar(x1, pmf1, color='skyblue')
axs[0].set_title('Exemplo 1: Prova de Múltipla Escolha\nn=5, p=0.5')
axs[0].set_xlabel('Número de acertos (k)')
axs[0].set_ylabel('Probabilidade')
axs[0].axhline(y=pmf1[2], color='red', linestyle='--', label=f'P(X=2)=
{pmf1[2]:.4f}')
axs[0].legend()

# Gráfico do Exemplo 2
axs[1].bar(x2, pmf2, color='lightgreen')
axs[1].set_title('Exemplo 2: Defeitos em Peças\nn=8, p=0.1')
axs[1].set_xlabel('Número de peças defeituosas (k)')
axs[1].set_ylabel('Probabilidade')
axs[1].axhline(y=pmf2[1], color='red', linestyle='--', label=f'P(X=1)=
{pmf2[1]:.4f}')
axs[1].legend()

plt.tight_layout()
plt.show()

```

Distribuição Poisson

O que é a Distribuição de Poisson?

A **Distribuição de Poisson** é uma distribuição de probabilidade discreta que descreve o número de **eventos que ocorrem em um intervalo fixo de tempo ou espaço, quando esses eventos acontecem de forma independente** e com uma **taxa média constante**.

Ela é ideal para modelar **eventos raros** ou **eventos que ocorrem de forma esparsa**.

Quando usar a Distribuição de Poisson?

Use Poisson quando:

- Os eventos são **independentes** entre si
 - A média de ocorrências por intervalo é **constante**
 - O número de eventos possíveis é **teoricamente infinito**, mas ocorrem poucos
-

Parâmetro principal: λ (lambda)

- Representa a **taxa média de ocorrência** de eventos por intervalo
 - Exemplo: $\lambda = 3 \rightarrow$ em média, 3 eventos por hora
-

 **Fórmula da distribuição de Poisson (sem aprofundar em matemática):**

A fórmula fornece a probabilidade de observar **k eventos** em um intervalo, dada uma média λ .

Exemplos do mundo real

1. **Chamadas em um call center:** Suponha que em média 5 ligações cheguem por minuto. A Poisson pode te dizer qual a chance de receber exatamente 3 ligações em um certo minuto.
 2. **Defeitos em um rolo de tecido:** Se em média ocorrem 2 defeitos por metro, você pode calcular a chance de ocorrerem exatamente 4 defeitos em 1 metro.
 3. **Acidentes de trânsito por dia em uma cidade:** Se ocorrem 10 por dia, qual a chance de ocorrerem 7 em um determinado dia?
-

Propriedades importantes

- A média e a variância da distribuição são **iguais**:
 $\mu = \lambda$ e $\sigma^2 = \lambda$
 - Quanto maior λ , mais a distribuição se parece com uma curva normal (gaussiana)
-

Passo a passo para aplicar a Poisson

Exemplo prático:

Em uma farmácia, chegam em média 4 clientes por hora. Qual a chance de chegarem **exatamente 2 clientes** em uma hora?

Etapas:

1. Identifique:
 - $\lambda = 4$ (média por hora)
 - $k = 2$ (número desejado de ocorrências)
 2. Use a fórmula da distribuição de Poisson, ou use Python (com `scipy.stats.poisson.pmf(k, λ)`)
 3. Interprete o resultado: A probabilidade será em torno de **0,1465** ou 14,65%
-

Resumo:

Conceito	Valor
Tipo de distribuição	Discreta
Parâmetro principal	λ (média de eventos)
Eventos	Independentes

Conceito	Valor
Exemplos	Chamadas, defeitos, pedidos
Média e variância	Iguais (λ)

Contexto do Exemplo:

Problema:

Uma central de atendimento recebe em média **4 ligações por minuto**.
Qual a probabilidade de receber **exatamente 2 ligações** em um minuto?

1. Identificar os dados do problema

- Média de eventos por intervalo (λ): **4**
- Número de eventos desejado (k): **2**
- Fórmula da distribuição de Poisson:

\$\$

$$P(k; \lambda) = \frac{e^{-\lambda} \cdot \lambda^k}{k!}$$

\$\$

2. Substituir os valores na fórmula:

\$\$

$$P(2; 4) = \frac{e^{-4} \cdot 4^2}{2!}$$

\$\$

3. Calcular os componentes:

- $e^{-4} \approx 0.0183$
- $4^2 = 16$
- $2! = 2$

4. Calcular a probabilidade:

\$\$

$$P(2; 4) = \frac{0.0183 \cdot 16}{2} = \frac{0.2928}{2} = 0.1464$$

\$\$

5. Conclusão:

A probabilidade de receber exatamente **2 ligações** em um minuto é **aproximadamente 14,64%**.

Se quiser, posso gerar também uma **visualização em gráfico** desse exemplo, destacando o valor de $k = 2$. Deseja isso?

Exemplo em python

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import poisson, binom, norm

# Parâmetros das distribuições
lambda_poisson = 4 # média para Poisson
n_binomial = 20 # número de tentativas na Binomial
p_binomial = 0.2 # probabilidade de sucesso na Binomial
mu_normal = 4 # média para Normal
sigma_normal = 2 # desvio padrão da Normal

# Eixos para valores discretos e contínuos
x_discrete = np.arange(0, 15)
x_continuous = np.linspace(0, 15, 500)

# Funções de probabilidade/densidade
poisson_pmf = poisson.pmf(x_discrete, lambda_poisson)
binomial_pmf = binom.pmf(x_discrete, n_binomial, p_binomial)
normal_pdf = norm.pdf(x_continuous, mu_normal, sigma_normal)

# Plotagem
plt.figure(figsize=(15, 5))

# Gráfico de Poisson
plt.subplot(1, 3, 1)
plt.stem(x_discrete, poisson_pmf, basefmt=" ", use_line_collection=True)
plt.title("Distribuição de Poisson ( $\lambda = 4$ )")
plt.xlabel("k (nº de eventos)")
plt.ylabel("P(k)")
plt.grid(True)

# Gráfico de Binomial
plt.subplot(1, 3, 2)
plt.stem(x_discrete, binomial_pmf, basefmt=" ", linefmt='orange',
markerfmt='ro', use_line_collection=True)
plt.title("Distribuição Binomial (n=20, p=0.2)")
plt.xlabel("k (sucessos)")
plt.ylabel("P(k)")
plt.grid(True)

# Gráfico de Normal
plt.subplot(1, 3, 3)
plt.plot(x_continuous, normal_pdf, color='green')
plt.title("Distribuição Normal ( $\mu = 4, \sigma = 2$ )")
plt.xlabel("x")
plt.ylabel("f(x)")
```

```
plt.grid(True)

# Exibe todos os gráficos
plt.tight_layout()
plt.show()
```

✅ O que você precisa para rodar:

- Python 3.x
- Bibliotecas: `matplotlib`, `numpy`, `scipy`

```
pip install matplotlib numpy scipy
```